Большие языковые модели в задачах адаптации визуального домена

Лабораторная работа 1 по дисциплине «Прикладные задачи машинного обучения».

Направление подготовки — прикладная математика и информатика. Профиль — прикладное машинное обучение.

Тема ВКР — «Сравнительный анализ методов выравнивания распределений для адаптации домена в задачах компьютерного зрения».

Краткий результат. Выполнено 2912 ответов в основном сравнении семи моделей, 455 ответов выбранной модели на отдельных данных и 18 запусков адаптации. По правилу source validation выбрана qwen25_3000, режим few. На Clipart test её Macro-F1 составляет 0,132; доля невалидных ответов — 0,0%. Из 195 целевых изображений принято 195 псевдометок. Полные значения и ограничения приведены далее.

Постановка задачи

При смене визуального домена классификатор сталкивается с отличиями фона, текстуры, освещения и стиля изображения. В Office-Home фотографии товаров, реальные сцены, художественные изображения и клипарт содержат один набор из 65 классов, но различаются распределениями признаков. ВКР посвящена сравнению методов, уменьшающих это различие. Лабораторная исследует дополнительный источник информации для адаптации — псевдометки мультимодальной языковой модели.

Мультимодальная LLM принимает изображение через визуальный энкодер и преобразует его представление в контекст языковой модели. Генеративная часть отвечает текстом. В данной работе ответом служит структурированная пара «идентификатор класса — уверенность». Поэтому сравнение проводится среди моделей, действительно генерирующих текст по изображению и инструкции. CLIP и ResNet не включены в число семи LLM.

В терминах адаптации домена заданы размеченные исходные данные Ds = {(xs, ys)} и целевые данные Dt = {xt}, метки которых недоступны обучаемому алгоритму. Цель — улучшить классификацию целевых изображений при различии Ps(x) и Pt(x). Основное направление — Product → Clipart. Выбранная LLM формирует предварительные метки target_adapt; последующий классификатор использует их как дополнительный член функции потерь. Истинные target-метки открываются только для оценки.

Исследовательский вопрос лабораторной: какая из доступных компактных мультимодальных LLM обеспечивает лучший баланс качества, валидности ответа, калибровки и затрат, и улучшают ли её псевдометки результаты MMD и CORAL в одинаковом протоколе?

Проверяются три содержательные гипотезы: few-shot улучшает классификацию относительно zero-shot; формально корректная высокая уверенность соответствует полезным псевдометкам; добавление псевдометок повышает качество адаптации при неизменном методе выравнивания. Направление эффекта проверяется экспериментом. Порог требуемого прироста заранее не устанавливался. Гипотезы и их интерпретация сформулированы как исследовательские; предварительная регистрация исследования не заявляется.

Поиск и аналитический обзор

Обзор основан на структурированном целевом поиске и переходах к первичным публикациям и авторским репозиториям. Основной запрос: ("Office-Home" OR "visual domain adaptation") AND ("distribution alignment" OR MMD OR CORAL OR adversarial). Дополнительный запрос: ("vision-language model" OR "multimodal language model") AND ("domain adaptation" OR "pseudo-labeling"). Отдельные запросы охватывали SmolVLM, Qwen2-VL, LLaVA, few-shot, эффективность, калибровку и русскоязычную ruCLIP.

Использованы CVF Open Access, PMLR, JMLR, arXiv и авторские страницы. Критерий включения — научная публикация или технический

отчёт, обосновывающий данные, выравнивание, мультимодальную модель, prompting, калибровку либо отечественный контекст. Вторичные пересказы и повторные версии одной статьи не включались. В журнале зарегистрированы 16 уникальных кандидатов; 15 вошли в обзор. Общая работа Brown et al. о текстовом few-shot исключена из итогового ядра в пользу непосредственно релевантной RCL 2026 года. Число найденных поисковой системой документов не фиксировалось, поэтому оно не восстанавливается задним числом. PRISMA-подобная схема описывает этот зарегистрированный корпус, а не исчерпывающий систематический поиск.

В корпусе есть статьи ведущих конференций и технические препринты; тип публикации и проверенные ранги площадок зафиксированы в literature/venue_ranks.json. Ранг площадки не переносится на workshop и не является оценкой отдельной статьи.

DAN [2] и Deep CORAL [4] показывают два способа согласовать распределения признаков. MMD сопоставляет средние представлений в пространстве ядра, CORAL — ковариационные матрицы. При одинаковой классификационной части различие их результатов позволяет исследовать вклад выбранной статистики. Однако совпадение маргинальных распределений не гарантирует правильного совмещения классов: ошибочное смешение, например, столов и стульев может уменьшать расхождение и одновременно ухудшать распознавание.

DANN [3] использует состязательное обучение доменного классификатора. CDAN [5] учитывает взаимодействие признаков и предсказаний, что подчёркивает значение семантической структуры. Эти работы мотивируют проверку надёжности меток, но не доказывают пользу внешних LLM-псевдометок в нашем протоколе. DANN и CDAN рассматриваются как следующие расширения ВКР; выполненное контролируемое сравнение ограничивается MMD и CORAL.

Office-Home [1] задаёт общие классы в разных визуальных стилях. Наш малый сбалансированный поднабор отличается от стандартных полных

протоколов, поэтому прямое сравнение с опубликованными значениями accuracy некорректно.

CLIP [6] связывает визуальное представление с текстовыми описаниями и служит концептуальной основой использования языковой семантики. Исследование Lai et al. [7] связывает предобученные vision-language модели с адаптацией и псевдометками. Однако контрастивная VLM и генеративная мультимодальная LLM имеют разные интерфейсы и ошибки. Здесь дополнительно требуется выполнить инструкцию, выбрать идентификатор из 65 вариантов и выдать валидный JSON. Ошибки формата являются самостоятельным источником потерь.

Семейства сравниваемых моделей описаны в LLaVA [8], SmolVLM [9], Qwen2-VL [10] и Qwen2.5-VL [11]. Несколько размеров SmolVLM позволяют сравнить масштаб модели, но уменьшают архитектурное разнообразие семи checkpoint.

Few-shot использует примеры в запросе без изменения весов; LoRA [12] обучает малый адаптер. Это разные механизмы, оцениваемые на отложенных данных без подбора по test.

Работа о калибровке [13] мотивирует проверку заявленной уверенности отдельно от точности: текстовое confidence не равно вероятности из logits. RuCLIP [15] мотивирует разведочную проверку русского языка инструкции, но не предсказывает её результат для наших моделей.

Chen et al. [14] уже исследуют передачу псевдометок от нескольких замороженных мультимодальных моделей компактному классификатору на Office-Home и других наборах. RCL использует согласие учителей и уверенность в трёхэтапном обучении. Это прямо подтверждает существование близкой постановки, поэтому сама идея LLM-разметки не объявляется новой. Отличие нашей лабораторной — доступный source-домен, семь компактных checkpoint, строгая JSON-оценка и отдельное сравнение вклада псевдометок в MMD и CORAL.

В отобранных работах не установлена пригодность именно этих семи checkpoint в едином JSON-протоколе Office-Home и влияние их псевдометок на сравнение MMD и CORAL. Полная матрица с данными, протоколами, метриками, кодом и ограничениями доступна в literature/matrix.csv.

Проверка рангов площадок по выпуску ICORE2026: Официальный портал ICORE

Схема отбора источников

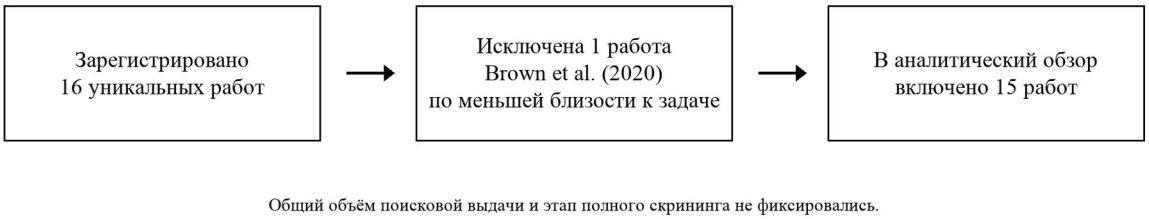


Рисунок 1 — Схема отбора зарегистрированных работ для аналитического обзора

Таблица 1 — Сравнительная матрица источников

№	Публикация	Метод или модель	Связь с работой
1	Venkateswara et al. 2017	Глубокая сеть с хеширующим представлением	данные
2	Long et al. 2015	DAN	MMD
3	Ganin et al. 2016	DANN	состязательное выравнивание
4	Sun and Saenko 2016	Deep CORAL	CORAL
5	Long et al. 2018	CDAN	условное выравнивание
6	Radford et al. 2021	CLIP	визуально-языковые признаки
7	Lai et al. 2024	Адаптация CLIP/GLIP и domain-aware pseudo-labeling	адаптация VLM
8	Liu et al. 2023	LLaVA	визуальные инструкции
9	Marafioti et al. 2025	SmolVLM	компактная MLLM
10	Wang et al. 2024	Qwen2-VL	семейство Qwen2-VL
11	Bai et al. 2025	Qwen2.5-VL	семейство Qwen2.5-VL

№	Публикация	Метод или модель	Связь с работой
12	Hu et al. 2022	Низкоранговые добавки при замороженных основных весах	адаптация LoRA
13	Guo et al. 2017	Анализ калибровки	калибровка
14	Chen et al. 2026	RCL	псевдометки MLLM
15	Shonenkov et al. 2022	Шесть реализаций ruCLIP	язык инструкции

Матрица охватывает 15 публикаций. Её полная версия с задачей, данными, протоколом, метриками, кодом, ограничениями и идеей репликации приложена как literature/matrix.csv.

Подготовка данных и защита от утечки

Единица наблюдения — одно изображение с меткой предмета и доменом. Источник — зеркало flwrlabs/office-home с фиксированным commit; первоисточник — сайт авторов Office-Home. Условия использования — Fair Use Notice для академических некоммерческих исследований. Разметка взята из датасета, дополнительная ручная переразметка не выполнялась.

Все 15 588 изображений прочитаны без ошибок декодирования. Проверены классовые частоты, размеры, точные повторы по SHA256 декодированных RGB-пикселей и кандидаты визуального сходства по pHash. Для последних применены расстояние Хэмминга не более 4 и различие пропорций не более 10%; это эвристика, а не доказательство тождества.

Выявлены 412 пар точных повторов и 1041 пара кандидатов сходства. До разбиения они объединены в группы; 104 группы с конфликтующими метками исключены. Ни одна выбранная группа не попала в две части. Число пар не является числом удалённых изображений.

Исследовательский поднабор содержит 1235 изображений, отобранных воспроизводимо по seed и SHA256. JPEG ограничены 448 пикселями по длинной стороне с сохранением пропорций. Это снижает затраты, но может ухудшать распознавание мелких деталей. Надёжных временных меток нет, поэтому хронологическое разбиение не заявляется.

Product разделён на source_train (520) и validation (130); для MLLM из validation заранее выбрано по одному изображению на класс (65). Все 130 validation участвуют в выборе эпохи классификатора. Clipart разделён на target_adapt (195) и test (130), Art и Real_World имеют по 130 изображений. Test и дополнительные срезы не участвуют в выборе модели.

Стратификация использует метки датасета только при построении benchmark; алгоритм адаптации целевых меток не получает. Результат относится к сбалансированному поднабору, а не к естественному потоку.

Таблица 2 — Состав полного набора Office-Home по доменам

Домен	**N**	**Min класс**	**Max класс**	**Дисбаланс**
Art	2427	15	99	6,60
Clipart	4365	39	99	2,54
Product	4439	38	99	2,61
Real_World	4357	23	99	4,30

Дисбаланс — отношение максимального к минимальному числу объектов класса. Статистика относится к полному прочитанному корпусу, до отбора исследовательского поднабора.

Таблица 3 — Разбиение исследовательского поднабора

Часть	**Домен**	**N**	**Доступ к меткам**
source_train	Product	520	Обучение
validation	Product	130	65 для LLM, 130 для классификатора
target_adapt	Clipart	195	Только итоговый аудит
test	Clipart	130	Только оценка
new_slice	Art	130	Только оценка
external	Real_World	130	Только оценка

Единый протокол сравнения

Сравниваются семь checkpoint. Для каждого выполнены zero-shot и three-shot. В three-shot показаны три фиксированных изображения source_train из классов 0, 22 и 43 с правильным структурированным ответом.

Это три демонстрации всего, а не три на каждый класс. Все модели видят одинаковые изображения и текстовый список классов. Варианты инструкций и идентификаторы демонстраций сохраняются вместе с журналом.

Ответ должен быть JSON-объектом ровно с двумя ключами: label_id — целое число от 0 до 64; confidence — число от 0 до 1. Markdown-обёртки, строковые числа, дополнительные ключи и текстовые пояснения нарушают схему. Принудительная грамматика и автоматическое исправление не применяются. Невалидный ответ получает техническую метку −1 и считается ошибкой. В Macro-F1 усреднение идёт по 65 настоящим классам, а не по добавленному классу INVALID.

Генерация жадная, максимум 40 новых токенов. SmolVLM использует longest_edge=512, Qwen — ограничение визуальных пикселей от 56^2 до 448^2, LLaVA — штатный процессор. Равный лимит генерации не означает одинаковые фактические затраты.

На одну модель приходится 416 ответов: 65 × 2 на source validation, 130 × 2 на test и 13 × 2 для дополнительных инструкций. Проверка чувствительности использует одни 13 тестовых изображений: английская перефразировка и русская формулировка задачи при неизменном английском перечне классов и JSON-требовании. Проверяется именно частичная смена языка инструкции, а не полностью русскоязычный интерфейс. Малый размер этой проверки позволяет только разведочный вывод.

Задержка охватывает подготовку запроса и генерацию с синхронизацией устройства; загрузка весов, прогрев и чтение JPEG исключены. Модели запускаются последовательно. Максимальный RSS и снимки памяти драйвера MPS записаны раздельно; последние не называются пиком GPU.

Qwen2-VL в float16 на MPS давала NaN в logits. После проверки оба Qwen запущены в штатной bfloat16, остальные модели — в float16. Первые 156 ошибочных пробных ответов исключены из метрик; изменение среды

зафиксировано в configs/runtime_amendment.json. Точность вычислений учитывается при интерпретации затрат.

Основная метрика — Macro-F1. Дополнительно рассчитываются accuracy, weighted F1, balanced accuracy и MCC. Калибровка оценивается ECE с десятью равными интервалами уверенности и бинарным Brier для события правильного ответа. Эти две метрики определены только на валидных ответах; вместе с ними обязательно указывается покрытие. Вывод «хорошая калибровка» недопустим по одному валидному ответу среди большого числа отказов.

Для Macro-F1 приведён 95% percentile bootstrap-интервал (2000 повторов внутри класса); режимы сравниваются парно. На validation с одним изображением на класс интервал не приводится, а на test с двумя объектами на класс он отражает лишь условную вариативность фиксированного поднабора.

Выбор модели и режима выполняется только на source validation. Сначала применяется порог невалидных ответов не выше 10%. Затем максимизируется $S = 0{,}6\ \text{Macro-F1} + 0{,}2\ (1 - \text{ECE}) + 0{,}1\ \text{valid_rate} + 0{,}1 / (1 + \text{latency_median} / 5)$. При неопределённой ECE соответствующий компонент равен нулю. Если никто не проходит порог, максимальный S используется только для исследовательского применения с явным указанием провала допуска. Это правило зафиксировано до основного сравнения; высокая метрика на test его не меняет.

Модели и версии

Таблица 4 — Семь мультимодальных моделей и число параметров

Ключ	**Checkpoint**	**Параметры млрд**
smol256	HuggingFaceTB/SmolVLM-256M-Instruct	0,256
smol500	HuggingFaceTB/SmolVLM-500M-Instruct	0,507
smol2_500	HuggingFaceTB/SmolVLM2-500M-Video-Instruct	0,507
smol2_2200	HuggingFaceTB/SmolVLM2-2.2B-Instruct	2,247

Ключ	Checkpoint	Параметры млрд
llava500	llava-hf/llava-interleave-qwen-0.5b-hf	0,864
qwen2_2000	Qwen/Qwen2-VL-2B-Instruct	2,209
qwen25_3000	Qwen/Qwen2.5-VL-3B-Instruct	3,755

Указано фактическое число параметров загруженного экземпляра, включая визуальную часть. Полные commit SHA находятся в configs/model_revisions.json; номинальный размер в названии может относиться только к языковой части.

По официальным карточкам SmolVLM, SmolVLM2 и Qwen2-VL-2B используют Apache-2.0; LLaVA Interleave Qwen 0.5B — Tongyi Qianwen Research License; Qwen2.5-VL-3B — Qwen Research License. Условия и ссылки зафиксированы в configs/model_cards_metadata.json. Отбор ограничен доступными для академического локального запуска checkpoint.

Первичная публикация, соответствующая использованному LLaVA-NeXT-Interleave checkpoint: F. Li et al., «LLaVA-NeXT-Interleave: Tackling Multi-image, Video, and 3D in Large Multimodal Models», 2024; статья arXiv. Сопоставление статьи и конкретной версии модели подтверждает официальная карточка checkpoint. Общая публикация LLaVA [8] остаётся архитектурной основой.

Качество на общем тесте

Значения в отчёте округлены до трёх знаков; малое ненулевое значение может отображаться как 0,000. Точные значения сохранены в CSV. Интервал [0,000; 0,000] на фиксированной выборке не доказывает нулевую точность на всей генеральной совокупности.

Таблица 5 — Качество моделей на общем тесте Clipart

Модель	Режим	Macro F1	95% ДИ	Accuracy	Invalid %
llava500	zero	0,001	0,001–0,001	0,015	3,1
llava500	few	0,000	0,000–0,000	0,015	0,0
qwen25_3000	zero	0,375	0,289–0,397	0,323	60,8

Модель	Режим	Macro F1	95% ДИ	Accuracy	Invalid %
qwen25_3000	few	0,132	0,093–0,151	0,138	0,0
qwen2_2000	zero	0,056	0,029–0,071	0,054	73,1
qwen2_2000	few	0,105	0,067–0,127	0,115	21,5
smol256	zero	0,000	0,000–0,000	0,000	100,0
smol256	few	0,000	0,000–0,000	0,000	100,0
smol2_2200	zero	0,167	0,137–0,184	0,215	3,1
smol2_2200	few	0,123	0,088–0,143	0,169	0,0
smol2_500	zero	0,000	0,000–0,000	0,000	99,2
smol2_500	few	0,000	0,000–0,000	0,000	100,0
smol500	zero	0,000	0,000–0,000	0,000	100,0
smol500	few	0,000	0,000–0,000	0,000	99,2

Таблица 6 — Дополнительные показатели классификации на общем тесте

Модель	Режим	Weighted F1	Balanced acc.	MCC
llava500	zero	0,001	0,015	0,001
llava500	few	0,000	0,015	0,000
qwen25_3000	zero	0,375	0,323	0,404
qwen25_3000	few	0,132	0,138	0,208
qwen2_2000	zero	0,056	0,054	0,074
qwen2_2000	few	0,105	0,115	0,112
smol256	zero	0,000	0,000	0,000
smol256	few	0,000	0,000	0,000
smol2_2200	zero	0,167	0,215	0,242
smol2_2200	few	0,123	0,169	0,181
smol2_500	zero	0,000	0,000	-0,001
smol2_500	few	0,000	0,000	0,000
smol500	zero	0,000	0,000	0,000
smol500	few	0,000	0,000	-0,001

Калибровка и вычислительные затраты

Таблица 7 — Калибровка и время ответа моделей

Модель	Режим	Valid N	ECE	Brier	p50 c	p95 c
llava500	zero	126	0,837	0,734	2,15	2,72

Модель	Режим	Valid N	ECE	Brier	p50 с	p95 с
llava500	few	130	0,970	0,956	9,27	11,35
qwen25_3000	zero	51	0,140	0,162	6,98	10,25
qwen25_3000	few	130	0,862	0,862	14,45	17,85
qwen2_2000	zero	35	0,616	0,542	3,80	4,72
qwen2_2000	few	102	0,853	0,853	9,89	13,17
smol256	zero	0	—	—	1,33	1,58
smol256	few	0	—	—	1,75	1,85
smol2_2200	zero	126	0,778	0,778	8,18	10,15
smol2_2200	few	130	0,831	0,831	31,36	47,98
smol2_500	zero	1	1,000	1,000	0,58	0,72
smol2_500	few	0	—	—	1,58	1,75
smol500	zero	0	—	—	0,68	0,94
smol500	few	1	1,000	1,000	1,81	1,98

Прочерк означает отсутствие валидных ответов, а не нулевую ошибку калибровки. Пиковый RSS и снимки памяти MPS приведены в results/memory_observations.csv; это разные показатели, их не суммируют. Неокруглённые метрики находятся в results/model_metrics.csv.

Разница few shot и zero shot

Положительная наблюдаемая разница получена для 1 из 7 моделей; нижняя граница парного интервала выше нуля для 1 моделей. Это не подтверждает универсальную пользу few-shot. Парные разницы и интервалы для всех моделей приведены в results/paired_mode_comparisons.csv; множественные сравнения не корректировались.

Чувствительность инструкции

Таблица 8 — Чувствительность моделей к формулировке инструкции

Модель	Вариант	N	Смена метки %	Accuracy	Invalid %
llava500	paraphrase	13	92,3	0,000	61,5
llava500	ru	13	92,3	0,000	0,0
qwen25_3000	paraphrase	13	53,8	0,000	100,0
qwen25_3000	ru	13	53,8	0,308	69,2

Модель	Вариант	N	Смена метки %	Accuracy	Invalid %
qwen2_2000	paraphrase	13	46,2	0,000	100,0
qwen2_2000	ru	13	53,8	0,000	92,3
smol256	paraphrase	13	0,0	0,000	100,0
smol256	ru	13	0,0	0,000	100,0
smol2_2200	paraphrase	13	23,1	0,231	0,0
smol2_2200	ru	13	0,0	0,154	0,0
smol2_500	paraphrase	13	7,7	0,000	100,0
smol2_500	ru	13	84,6	0,000	15,4
smol500	paraphrase	13	0,0	0,000	100,0
smol500	ru	13	0,0	0,000	100,0

Все невалидные ответы кодируются −1. Поэтому нулевая смена метки при двух разных невалидных текстах не означает устойчивое следование инструкции. Для интерпретации вместе рассматриваются raw-ответы, accuracy и invalid rate.

Для выбранной модели вариант paraphrase: accuracy базовой инструкции на тех же 13 изображениях 0,385; нового варианта 0,000. Проверка использует zero-shot независимо от режима итогового выбора.

Для выбранной модели вариант ru: accuracy базовой инструкции на тех же 13 изображениях 0,385; нового варианта 0,308. Проверка использует zero-shot независимо от режима итогового выбора.

Выбор модели на validation

Зафиксирован выбор qwen25_3000, few, S = 0,501. Проверка порога валидности: пройдена.

Результаты всех кандидатов на Product validation, включая балл S, находятся в results/model_metrics.csv. Тестовый Clipart не использовался для выбора.

Максимальный наблюдаемый тестовый Macro-F1 получен у qwen25_3000 в режиме zero: 0,375. У выбранной по source validation модели и режима он равен 0,132. Выбор после просмотра test не изменялся.

Расхождение этих значений показывает ограничение переноса правила выбора с Product на Clipart.

Параметрически эффективная адаптация

Дополнительный эксперимент LoRA выполнен для SmolVLM-500M: rank 8, alpha 16, dropout 0,05, q_proj/v_proj языковой части. Обучаемых параметров 819,200 из 508,301,504. Две эпохи, 520 source_train, AdamW 10^{-4}, накопление градиента 8, checkpoint по минимальной cross-entropy ответов на 65 source validation. Выбрана эпоха 2. Длительность 28,9 мин; максимум RSS 2,49 GB.

Таблица 9 — Результат дополнительной адаптации LoRA

Режим	**N test**	**Macro F1**	**Invalid %**	**ECE**
zero	130	0,000	100,0	—
few	130	0,000	99,2	1,000
lora	130	0,001	0,0	0,992

После LoRA правильно классифицировано 1 из 130 тестовых изображений. Accuracy = 0,0077, Macro-F1 = 0,000522. Улучшение формата ответа оценивается отдельно от содержательной точности разметки.

Cross-entropy обучения усредняется по всем токенам ответа. Большинство из них относится к постоянному JSON-шаблону и confidence=1,0; идентификатор класса занимает малую часть ответа. Поэтому уменьшение этой cross-entropy не равнозначно росту точности классификации. Возможный вклад такого дисбаланса токенов следует проверять отдельным экспериментом, например изменяя вес токенов label_id; причиной всех наблюдаемых ошибок он здесь не объявляется.

LoRA добавлена как отдельное разведочное расширение после начала основного сравнения. Она не участвует задним числом в выборе одной из семи базовых моделей. Обучающие ответы содержали confidence=1,0: это может усиливать чрезмерную уверенность и не является калибровочным обучением. Истинные target-метки не использовались.

Ошибки и предметные срезы

На test встречались ответы в блоке Markdown, JSON не в виде объекта, ошибки схемы и синтаксиса. Категории взаимно исключаются; их частоты приведены в results/schema_errors.csv. Ответы не исправлялись для метрик или выбора модели.

Анализ ошибок по классам сохранён в results/per_class.csv, по длине входных и выходных токенов, языку инструкции, площади исходного изображения и домену — в results/error_strata.csv. В Office-Home нет финансовых сообщений, поэтому соответствующий пункт задания интерпретируется как тип визуального домена. Длины и размеры рассматриваются описательно: они не рандомизированы, группы могут различаться составом объектов. В языковых сравнениях одни изображения повторяются, их нельзя считать независимыми.

Для выбранной модели и режима хотя бы одно правильное предсказание наблюдается в 13 из 65 классов; суммарно верны 18 из 130 изображений test. Это показывает, почему одной общей accuracy недостаточно для анализа распределения ошибок по классам.

Срезы по площади изображения и длине ответа доступны в results/error_strata.csv. Их различия описательные: размеры связаны с составом объектов, поэтому причину ошибки по ним установить нельзя. Влияние языка оценено на 13 повторно использованных изображениях.

У выбранной модели 112 валидных ошибочных ответов; 112 из них имеют confidence не ниже 0,7. Наличие таких ответов показывает, что установленный порог уверенности не гарантирует точности псевдометки. По этим тестовым ошибкам порог не перенастраивался.

Наиболее частые пары ошибочных классов указаны в results/selected_error_summary.json. При двух изображениях каждого истинного класса эти частоты неустойчивы. Десять примеров ниже выбраны из разных классов и не предназначены для оценки распространённости ошибок.

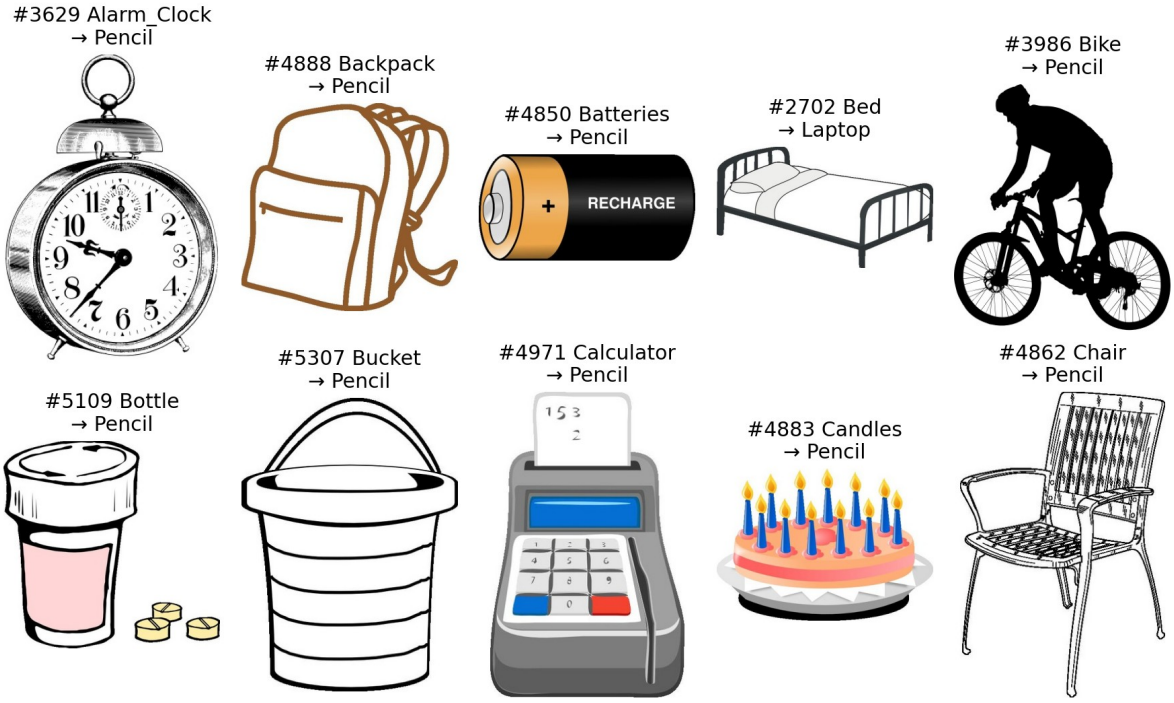


Рисунок 2 — Десять реальных ошибок с идентификаторами исходных изображений

Идентификаторы, настоящие и предсказанные классы видны на рисунке; исходные ответы и типы всех десяти ошибок содержатся в results/ten_errors.json. Полная confusion matrix с колонкой INVALID приложена в CSV и PNG.

Связь псевдометок с выравниванием распределений

Для отделения вклада методов используется один замороженный ResNet18 с весами ImageNet. Признаки размерности 512 стандартизуются средним и стандартным отклонением только source_train. Обучаемая часть состоит из линейного отображения 512 → 128, ReLU и классификатора 128 → 65. Все условия имеют одинаковые исходные признаки, инициализацию при одном seed, порядок исходных батчей, оптимизатор и число эпох.

Сравниваются шесть условий: без выравнивания, MMD и CORAL, каждое с псевдометками и без. При отсутствии выравнивания и псевдометок получается source-only baseline. Для каждого условия выполняются три seed. Максимум 40 эпох, batch 64, AdamW с learning rate 0,001 и weight decay 0,0001. Сохраняется эпоха с максимальным Macro-F1 на source validation.

Общая функция потерь L = Lsource + 0,1 Lalign + 0,3 Lpseudo. Неиспользуемые компоненты равны нулю. MMD вычисляется как среднее ядра внутри source плюс среднее внутри target минус удвоенное среднее между ними. Используется среднее трёх гауссовых ядер с масштабами 0,5; 1; 2, нормированное квадратное расстояние на размерность признаков, biased-оценка. CORAL равна квадрату нормы разности ковариаций, делённому на $4d^2$, d = 128.

В Lpseudo входят только валидные псевдометки с confidence ≥ 0,7. Истинные классы target_adapt не используются для обучения, настройки порога или выбора эпохи. Их сопоставление с псевдометками выполняется как отдельный аудит качества. Если принятых меток нет, эксперимент честно фиксирует отсутствие этого обучающего сигнала.

Результаты усреднены по трём seed; SD показывает разброс обучений, а не доверительный интервал. Эффект псевдометок оценивается парно при одинаковом seed. Art — дополнительная проверка классификатора после адаптации на Clipart. Одинаковый коэффициент 0,1 не гарантирует одинаковый масштаб MMD и CORAL; сравнение относится к заданным параметрам.

Применение выбранной модели к отдельным данным

Таблица 10 — Качество выбранной модели на отдельных визуальных доменах

Срез	**N**	**Macro F1**	**Accuracy**	**Invalid %**
Clipart	195	0,153	0,133	0,0
Art	130	0,216	0,223	0,0
Real_World	130	0,397	0,400	0,0

Принято 195 из 195 псевдометок. Точность принятых меток при отдельном аудите: 0,133. Эта проверка не использовалась для изменения порога 0,7 или подбора методов.

Правильных принятых меток: 26. В принятых предсказаниях представлены 26 из 65 классов; наиболее частый класс — Pencil, 152 ответов

из 195. Преобладание одного класса показывает смещение распределения псевдометок относительно сбалансированной целевой выборки.

Этот класс представлен среди трёх few-shot демонстраций. Возможное влияние примеров остаётся гипотезой: отдельная проверка состава демонстраций здесь не выполнена.

Результаты адаптации

Таблица 11 — Результаты сравнения способов выравнивания

Домен оценки	Метод	Псевдометки	Macro F1 ± SD	Accuracy ± SD
Clipart	Без выравн.	нет	0,251 ± 0,032	0,295 ± 0,035
Clipart	Без выравн.	да	0,123 ± 0,006	0,121 ± 0,004
Clipart	MMD	нет	0,256 ± 0,034	0,300 ± 0,035
Clipart	MMD	да	0,116 ± 0,011	0,115 ± 0,008
Clipart	CORAL	нет	0,251 ± 0,030	0,295 ± 0,035
Clipart	CORAL	да	0,115 ± 0,003	0,115 ± 0,000
Art	Без выравн.	нет	0,337 ± 0,024	0,374 ± 0,019
Art	Без выравн.	да	0,292 ± 0,030	0,292 ± 0,023
Art	MMD	нет	0,342 ± 0,025	0,379 ± 0,022
Art	MMD	да	0,306 ± 0,023	0,300 ± 0,020
Art	CORAL	нет	0,339 ± 0,024	0,377 ± 0,020
Art	CORAL	да	0,287 ± 0,020	0,290 ± 0,016

Вклад выравнивания относительно общего baseline

Вклад выравнивания относительно общего baseline рассчитан попарно при одинаковом seed и наличии псевдометок; полная таблица находится в results/adaptation/alignment_effects.csv. Следующий показатель сравнивает добавление псевдометок при неизменном методе.

Без выравн.: средняя парная разница Macro-F1 от добавления псевдометок -0,128; SD разницы между seed 0,027.

MMD: средняя парная разница Macro-F1 от добавления псевдометок -0,140; SD разницы между seed 0,036.

CORAL: средняя парная разница Macro-F1 от добавления псевдометок -0,136; SD разницы между seed 0,030.

Знак разницы отражает наблюдаемый эффект на этом поднаборе. Три seed и один target-домен не дают оснований утверждать универсальное превосходство метода или статистическую значимость только по знаку среднего.

Прототип и отказ от автоматического решения

Будущий прототип принимает изображение, выполняет проверку технической пригодности и запрашивает выбранную LLM. Строгий парсер проверяет формат, диапазон класса и уверенность. Невалидный или недостаточно уверенный ответ направляется на ручную разметку; данные вне набора 65 классов также требуют ручного рассмотрения. Сохранённая псевдометка содержит версию модели, инструкцию, исходный ответ и идентификатор изображения, чтобы её можно было проверить или заменить.

Входы с предметами вне 65 классов требуют отдельного детектора неизвестных классов или предварительной проверки оператором. Текущий закрытый benchmark такого детектора не реализует и не доказывает способность LLM самостоятельно обнаруживать все неизвестные объекты.

Автоматическое применение разрешается только после успешной проверки модели на validation и предметной оценки качества принятых меток. Порог 0,7 сам по себе не гарантирует точности. Для нового домена следует повторно проверить покрытие и ошибки; при ухудшении показателей возвращаться к ручной разметке. В лабораторной применение остаётся исследовательским и не выдаётся за готовую промышленную систему.

Ограничения и следующий эксперимент ВКР

Исследование ограничено одним основным направлением адаптации, малым сбалансированным поднабором, компактными моделями и

родственными checkpoint. Предобучающие корпуса моделей не полностью известны, поэтому наличие изображений Office-Home в предобучении исключить нельзя. pHash снижает риск внутридатасетной утечки, но не решает вопрос загрязнения предобучающих данных.

Общий JSON-протокол измеряет одновременно распознавание, выбор класса, следование инструкции и соблюдение формата. Низкий результат не означает, что модель вообще не умеет описывать изображения. Уверенность сформулирована текстом, чувствительность инструкции проверяется на 13 объектах, задержки измерены на одном устройстве. Source validation не гарантирует оптимальный выбор для нового target-домена.

Число входных токенов включает и текстовые, и специальные визуальные токены, поэтому этот срез не интерпретируется как чистая длина текста. Выходные токены относятся к текстовому ответу. Внутри одного режима текст основной инструкции одинаков, а различия few-shot включают одновременно дополнительный текст и изображения; их отдельный причинный вклад здесь не идентифицируется.

Следующий эксперимент ВКР должен охватить полные 12 направлений Office-Home, увеличить тестовые выборки, добавить DANN и CDAN, проверить несколько коэффициентов выравнивания по допустимому правилу без доступа к target test и повторить сравнение на нескольких seed. Следует отдельно проверить, сохраняется ли вклад псевдометок после выравнивания, и сравнить их с собственными псевдометками классификатора и независимым контрастивным baseline. Эксперимент со свободным ответом и нормализацией класса возможен как новый протокол, но его нельзя задним числом смешивать с текущей строгой JSON-оценкой.

Вывод по исследовательскому вопросу

В заданном протоколе многокритериальное правило выбрало qwen25_3000 в режиме few. Тестовый Macro-F1 равен 0,132, интервал 0,093–

0,151. Это результат конкретной версии модели, инструкции и поднабора, а не общий рейтинг мультимодальных LLM.

Польза few-shot оказалась зависимой от модели: положительное изменение наблюдалось у 1 из семи checkpoint. Корректность JSON и уверенность необходимо проверять отдельно от содержательного распознавания.

Гипотеза о полезности формально корректных уверенных псевдометок не подтверждается самим прохождением порога: среди принятых меток target_adapt правильны 26 из 195. Для автоматической разметки нового домена требуется независимая проверка содержательной точности; высокий confidence в этом опыте её не заменяет.

В сравнении без внешних псевдометок наибольший наблюдаемый средний Macro-F1 получен у mmd: 0,256 ± 0,034 SD. Это описание данного пилотного результата; статистически доказанное или универсальное превосходство метода не заявляется.

Для сравнения методов выравнивания подтверждены следующие измеренные изменения после добавления псевдометок: Без выравн. -0,128 Macro-F1; MMD -0,140 Macro-F1; CORAL -0,136 Macro-F1. Гипотеза о безусловном улучшении от внешней разметки из этих результатов не следует. Тема ВКР сохраняется: дальнейший анализ должен оценивать методы выравнивания в одинаковых условиях и отделять их эффект от качества внешних меток.

Воспроизводимые артефакты

В комплект входят исходный код, notebook анализа, README, матрица литературы и BibTeX, паспорт и аудит данных, manifest, конфигурации запросов, версии checkpoint, сырые ответы, таблицы метрик, графики и десять ошибок. Порядок повторения приведён в README.md. Скачанные веса после расчётов удаляются; их ревизии сохраняются для повторной загрузки.

Репозиторий студента: https://github.com/allinkins/lab1-officehome-domain-adaptation

Список литературы

Нумерация записей соответствует ссылкам в тексте и строкам сравнительной матрицы. Описания содержат подтверждённые выходные данные и адреса первоисточников; дата обращения к электронным версиям — 9 октября 2026 года.

[1] Deep Hashing Network for Unsupervised Domain Adaptation / H. Venkateswara, J. Eusebio, S. Chakraborty [et al.] // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2017. — P. 5018–5027. — URL: https://openaccess.thecvf.com/content_cvpr_2017/html/Venkateswara_Deep_Hashing_Network_CVPR_2017_paper.html (дата обращения: 09.10.2026). — Текст : электронный.

[2] Learning Transferable Features with Deep Adaptation Networks / M. Long, Y. Cao, J. Wang [et al.] // Proceedings of the 32nd International Conference on Machine Learning. — 2015. — Vol. 37. — P. 97–105. — URL: https://proceedings.mlr.press/v37/long15.html (дата обращения: 09.10.2026). — Текст : электронный.

[3] Domain-Adversarial Training of Neural Networks / Y. Ganin, E. Ustinova, H. Ajakan [et al.] // Journal of Machine Learning Research. — 2016. — Vol. 17. — No. 59. — P. 1–35. — URL: https://jmlr.org/papers/v17/15-239.html (дата обращения: 09.10.2026). — Текст : электронный.

[4] Sun, B. Deep CORAL: Correlation Alignment for Deep Domain Adaptation / B. Sun, K. Saenko // Computer Vision – ECCV 2016 Workshops. — 2016. — Vol. 9915. — P. 443–450. — DOI: 10.1007/978-3-319-49409-8_35. — URL: https://arxiv.org/abs/1607.01719 (дата обращения: 09.10.2026). — Текст : электронный.

[5] Conditional Adversarial Domain Adaptation / M. Long, Z. Cao, J. Wang [et al.] // Advances in Neural Information Processing Systems. — 2018. — Vol. 31. — URL: https://proceedings.neurips.cc/paper_files/paper/2018/hash/ab88b15733f543179858600245108dd8-Abstract.html (дата обращения: 09.10.2026). — Текст : электронный.

[6] Learning Transferable Visual Models From Natural Language Supervision / A. Radford, J. W. Kim, C. Hallacy [et al.] // Proceedings of the 38th International Conference on Machine Learning. — 2021. — Vol. 139. — P. 8748–8763. — URL: https://proceedings.mlr.press/v139/radford21a.html (дата обращения: 09.10.2026). — Текст : электронный.

[7] Empowering Unsupervised Domain Adaptation With Large-Scale Pre-Trained Vision-Language Models / Z. Lai, H. Bai, H. Zhang [et al.] // Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). — 2024. — P. 2691–2701. — URL: https://openaccess.thecvf.com/content/WACV2024/html/Lai_Empowering_Unsupervised_Domain_Adaptation_With_Large-Scale_Pre-Trained_Vision-Language_Models_WACV_2024_paper.html (дата обращения: 09.10.2026). — Текст : электронный.

[8] Visual Instruction Tuning / H. Liu, C. Li, Q. Wu [et al.] // Advances in Neural Information Processing Systems. — 2023. — Vol. 36. — URL: https://proceedings.neurips.cc/paper_files/paper/2023/hash/6dcf277ea32ce3288914faf369fe6de0-Abstract-Conference.html (дата обращения: 09.10.2026). — Текст : электронный.

[9] SmolVLM: Redefining small and efficient multimodal models / A. Marafioti, O. Zohar, M. Farré [et al.] // Conference on Language Modeling (COLM). — 2025. — URL: https://arxiv.org/abs/2504.05299 (дата обращения: 09.10.2026). — Текст : электронный.

[10] Qwen2-VL: Enhancing Vision-Language Model’s Perception of the World at Any Resolution / P. Wang, S. Bai, S. Tan [et al.] // arXiv. — 2024. —

arXiv:2409.12191. — URL: https://arxiv.org/abs/2409.12191 (дата обращения: 09.10.2026). — Текст : электронный.

[11] Qwen2.5-VL Technical Report / S. Bai, K. Chen, X. Liu [et al.] // arXiv. — 2025. — arXiv:2502.13923. — URL: https://arxiv.org/abs/2502.13923 (дата обращения: 09.10.2026). — Текст : электронный.

[12] LoRA: Low-Rank Adaptation of Large Language Models / E. J. Hu, Y. Shen, P. Wallis [et al.] // International Conference on Learning Representations (ICLR). — 2022. — URL: https://openreview.net/forum?id=nZeVKeeFYf9 (дата обращения: 09.10.2026). — Текст : электронный.

[13] On Calibration of Modern Neural Networks / C. Guo, G. Pleiss, Y. Sun [et al.] // Proceedings of the 34th International Conference on Machine Learning. — 2017. — Vol. 70. — P. 1321–1330. — URL: https://proceedings.mlr.press/v70/guo17a.html (дата обращения: 09.10.2026). — Текст : электронный.

[14] Empowering Source-Free Domain Adaptation via MLLM-Guided Reliability-Based Curriculum Learning / D. Chen, K. Patwari, Z. Lai [et al.] // Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). — 2026. — P. 4262–4272. — URL: https://openaccess.thecvf.com/content/WACV2026/html/Chen_Empowering_Source-Free_Domain_Adaptation_via_MLLM-Guided_Reliability-Based_Curriculum_Learning_WACV_2026_paper.html (дата обращения: 09.10.2026). — Текст : электронный.

[15] RuCLIP — new models and experiments: a technical report / A. Shonenkov, A. Kuznetsov, D. Dimitrov [et al.] // arXiv. — 2022. — arXiv:2202.10784. — URL: https://arxiv.org/abs/2202.10784 (дата обращения: 09.10.2026). — Текст : электронный.